CAT-IA

Soporte con evidencia

Clasificación de tickets y respuestas fundamentadas con LLM + RAG.

Nexo TI · Organización ficticia académica.

Autoras: Antonella Cuvertino y Miriam Hammami.

Docente: Sebastián Ignacio Sánchez Morales.

ISY0101 · Entrega: 09/09/2026 · Sección: pendiente de informar.

01 · El problema

1. La mesa de ayuda debe clasificar y consultar procedimientos dispersos.
2. La urgencia escrita no siempre representa el impacto real.
3. Un borrador sin evidencia puede inventar políticas o compromisos.
4. Hipótesis: asistencia contextual mejora consistencia y tiempo de triage.

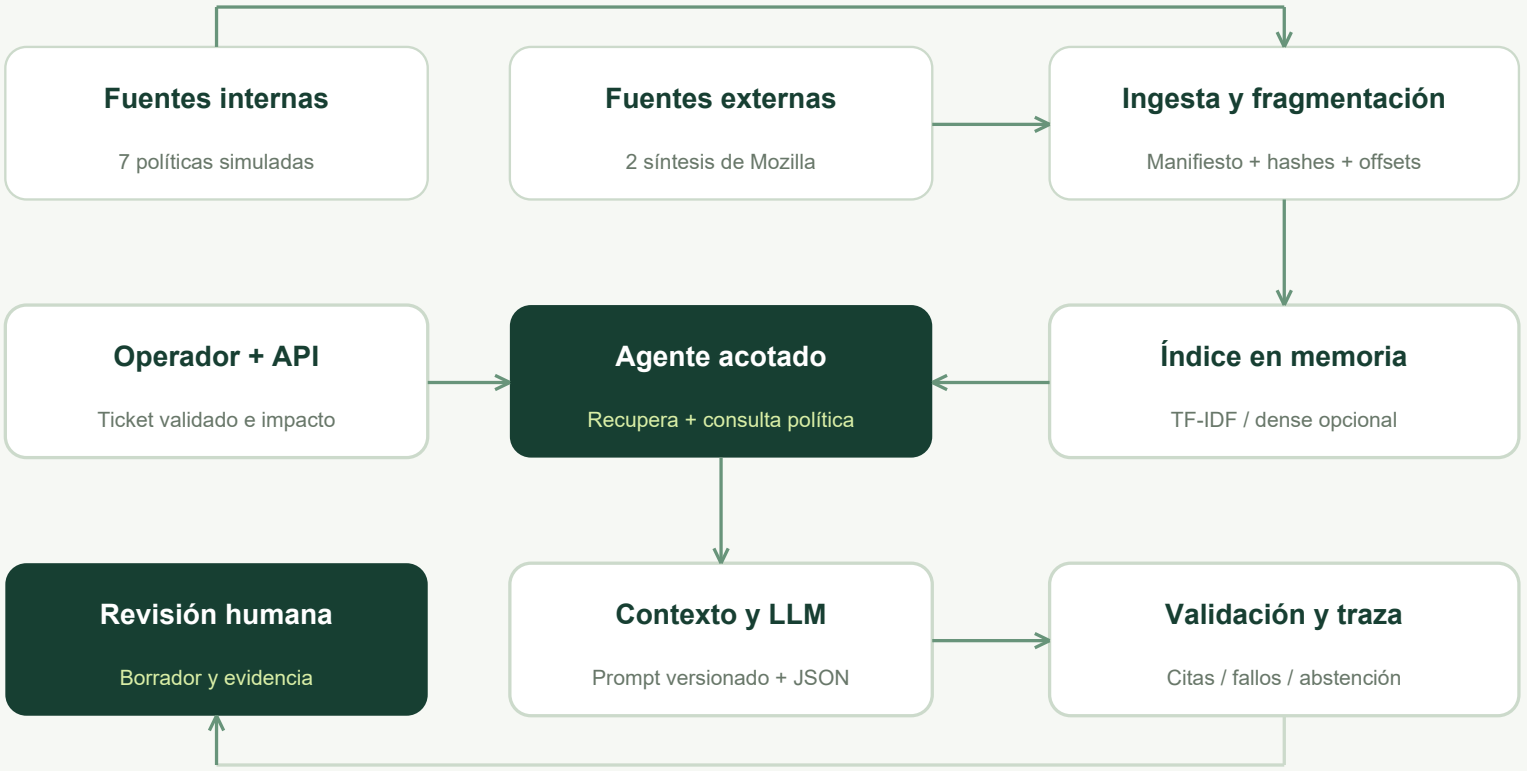
02 · Caso y objetivos

1. Nexo TI: escenario ficticio de soporte a pymes; datos internos simulados.
2. Meta: macro-F1 de clasificación ≥ 0,85 con evaluación real del LLM.
3. Meta: recall documental ≥ 0,85 y precisión ≥ 0,70.
4. Alcance: preparar un borrador; la decisión final sigue siendo humana.

03 · Fuentes de conocimiento

1. 7 documentos internos: SLA, acceso, facturación, comercial, mejoras, red y seguridad.
2. 2 síntesis de fuentes reales de Mozilla: cookies y conectividad de Firefox.
3. Manifiesto: origen, tipo, versión, transformación, fecha y SHA-256.
4. 28 tickets sintéticos: 8 desarrollo + 20 prueba; no forman parte del índice.

04 · Arquitectura de la solución



Sin evidencia o salida inválida: abstenerse y derivar. La prioridad se aplica con política interna.

El diagrama editable Mermaid contiene todas las conexiones; dense es opcional y requiere modelo.

05 · Cómo recuperamos evidencia

1. Fragmentos de 110 palabras; solapamiento de 20.
2. Baseline: TF-IDF y similitud coseno; no es embedding neuronal.
3. k=4, umbral inicial 0,06 y límite de 6500 caracteres documentales.
4. Embeddings densos opcionales: requieren evaluación separada y calibración.

06 · Prompts y control de contexto

1. v1: zero-shot; v2: contexto y ejemplos; v3: taxonomía ajustada con errores medidos.
2. Instrucciones separadas del ticket y de los documentos.
3. No inventar precios, devoluciones ni plazos de resolución.
4. Solicitar citas y justificación breve; abstenerse si falta evidencia.

07 · Generación y validación

1. Ollama: LLM local con JSON Schema y temperatura 0.
2. Pydantic valida campos y categorías; el agente verifica citas exactas.
3. Una cita real no demuestra que la recomendación esté respaldada.
4. Demo es un simulador explícito; nunca oculta un fallo del LLM.

08 · Demostración

1. Ticket Firefox: recuperar una guía externa y un procedimiento interno.
2. Mostrar categoría, prioridad, borrador, citas y recorrido.
3. Ticket de astronomía: comprobar abstención.
4. URGENTE comercial: explicar por qué permanece Baja con impacto individual.

09 · Pruebas y resultados

1. Software: 33 pruebas, 0 fallos; cobertura 94.5 %.
2. Recuperación lexical: precisión 80.1%; recall 100.0% en 20 casos sintéticos.
3. Regresión sintética con Qwen 2.5 1.5B: macro-F1 1.000; p50 45.4 s en CPU.
4. Fidelidad y relevancia: revisión humana pendiente; no inferirlas de las citas.

10 · Decisiones de ingeniería

1. Monolito modular: menor operación y responsabilidades separadas.
2. RAG: conocimiento actualizable y trazable sin reentrenar.
3. Política determinista: primera respuesta por impacto declarado.
4. Trazas locales: hashes y tiempos sin persistir el texto del ticket.

11 · Límites y próximos pasos

1. Caso ficticio y aprobación docente por confirmar.
2. Completar revisión humana de fidelidad y relevancia de las respuestas.
3. El test se usó para ajustar v3: falta validación con casos nuevos.
4. Antes de producción: autenticación, permisos, privacidad y piloto real.

12 · Cambio en vivo y cierre

1. Variar k o incorporar una fuente y repetir el mismo caso.
2. Explicar el efecto con evidencia, sin prometer mejora automática.
3. El valor de CAT-IA es asistir con contexto y hacer revisable el resultado.
4. Preguntas y revisión del código.