

CAT-IA

Soporte con evidencia

Clasificación de tickets y respuestas fundamentadas con LLM + RAG.

Nexo TI · Organización ficticia académica.

Integrantes: completar nombres · ISY0101 · Sección: completar.

01 · El problema

- 1 La mesa de ayuda debe clasificar y consultar procedimientos dispersos.
- 2 La urgencia escrita no siempre representa el impacto real.
- 3 Un borrador sin evidencia puede inventar políticas o compromisos.
- 4 Hipótesis: asistencia contextual mejora consistencia y tiempo de triage.

02 · Caso y objetivos

- 1 Nexo TI: escenario ficticio de soporte a pymes; datos internos simulados.
- 2 Meta: macro-F1 de clasificación $\geq 0,85$ con evaluación real del LLM.
- 3 Meta: recall documental $\geq 0,85$ y precisión $\geq 0,70$.
- 4 Alcance: preparar un borrador; la decisión final sigue siendo humana.

03 · Fuentes de conocimiento

- 1 7 documentos internos: SLA, acceso, facturación, comercial, mejoras, red y seguridad.
- 2 2 síntesis de fuentes reales de Mozilla: cookies y conectividad de Firefox.
- 3 Manifiesto: origen, tipo, versión, transformación, fecha y SHA-256.
- 4 28 tickets sintéticos: 8 desarrollo + 20 prueba; no forman parte del índice.

04 · Arquitectura de la solución



Sin evidencia o salida inválida: abstenerse y derivar. La prioridad se aplica con política interna.
El diagrama editable Mermaid contiene todas las conexiones; dense es opcional y requiere modelo.

05 · Cómo recuperamos evidencia

- 1 Fragmentos de 110 palabras; solapamiento de 20.
- 2 Baseline: TF-IDF y similitud coseno; no es embedding neuronal.
- 3 $k=4$, umbral inicial 0,06 y límite de 6500 caracteres documentales.
- 4 Embeddings densos opcionales: requieren evaluación separada y calibración.

06 · Prompts y control de contexto

- 1 v1: zero-shot; v2: contexto y ejemplos; v3: taxonomía ajustada con errores medidos.
- 2 Instrucciones separadas del ticket y de los documentos.
- 3 No inventar precios, devoluciones ni plazos de resolución.
- 4 Solicitar citas y justificación breve; abstenerse si falta evidencia.

07 · Generación y validación

- 1 Ollama: LLM local con JSON Schema y temperatura 0.
- 2 Pydantic valida campos y categorías; el agente verifica citas exactas.
- 3 Una cita real no demuestra que la recomendación esté respaldada.
- 4 Demo es un simulador explícito; nunca oculta un fallo del LLM.

08 · Demostración

- 1 Ticket Firefox: recuperar una guía externa y un procedimiento interno.
- 2 Mostrar categoría, prioridad, borrador, citas y recorrido.
- 3 Ticket de astronomía: comprobar abstención.
- 4 URGENTE comercial: explicar por qué permanece Baja con impacto individual.

09 · Pruebas y resultados

- 1 Software: 33 pruebas, 0 fallos; cobertura 94.5 %.
- 2 Recuperación lexical: precisión 80.1%; recall 100.0% en 20 casos sintéticos.
- 3 Regresión sintética con Qwen 2.5 1.5B: macro-F1 1.000; p50 45.4 s en CPU.
- 4 Fidelidad y relevancia: revisión humana pendiente; no inferirlas de las citas.

10 · Decisiones de ingeniería

- 1 Monolito modular: menor operación y responsabilidades separadas.
- 2 RAG: conocimiento actualizable y trazable sin reentrenar.
- 3 Política determinista: primera respuesta por impacto declarado.
- 4 Trazas locales: hashes y tiempos sin persistir el texto del ticket.

11 · Límites y próximos pasos

- 1 Caso ficticio y aprobación docente por confirmar.
- 2 Completar revisión humana de fidelidad y relevancia de las respuestas.
- 3 El test se usó para ajustar v3: falta validación con casos nuevos.
- 4 Antes de producción: autenticación, permisos, privacidad y piloto real.

12 · Cambio en vivo y cierre

- 1 Variar k o incorporar una fuente y repetir el mismo caso.
- 2 Explicar el efecto con evidencia, sin prometer mejora automática.
- 3 El valor de CAT-IA es asistir con contexto y hacer revisable el resultado.
- 4 Preguntas y revisión del código.